



UNIVERSIDADE FEDERAL DE CAMPINA GRANDE
PRÓ-REITORIA DE PÓS-GRADUAÇÃO E PESQUISA
COORDENAÇÃO GERAL DE PESQUISA

RELATÓRIO DE ATIVIDADES DO ALUNO

Programa: PIBIT

Título do Projeto: Desenvolvimento de um Sistema de Geração Automática de Laudos Médicos por Reconhecimento de Voz e Processamento de Linguagem Natural

Aluno: João Ventura Crispim Neto

Orientador: Tiago Lima Massoni

Assinatura do(a) aluno(a):

Assinatura do(a) orientador(a):

Local e Data

Atividades Realizadas

No período inicial do projeto, realizamos um levantamento exploratório do contexto assistencial, com foco na compreensão dos processos envolvidos na realização do exame citopatológico do colo do útero. Nesse sentido, foram realizadas três visitas à Unidade da Mulher do Hospital Universitário Alcides Carneiro (HUAC/UFCG), setor responsável pela coleta das amostras a serem enviadas para análise. Essa etapa teve como objetivo a observação do fluxo de atendimento, desde a coleta do material biológico até o encaminhamento das amostras para análise, permitindo a identificação dos pontos de interação entre os serviços assistenciais e os sistemas de informação utilizados.

Em seguida, procedeu-se à análise do fluxo técnico-laboratorial no setor de Patologia, contemplando as etapas de preparo das lâminas, leitura citológica, classificação dos achados e emissão dos laudos. Nessa fase, foi dada especial atenção à estrutura dos documentos gerados, aos padrões terminológicos adotados e à organização das informações clínicas e diagnósticas.

Com base nessas observações, foi elaborado um mapeamento detalhado do fluxograma de trabalho, evidenciando os atores envolvidos, os pontos de decisão e os sistemas utilizados ao longo do processo. O fluxograma retrata as etapas do processo na Unidade Básica de Saúde (UBS) (Figura 1), Unidade da Mulher (Figura 2) e HUAC (Figura 3). Essa análise permitiu uma avaliação crítica da aderência do contexto real à proposta tecnológica inicialmente delineada. Tal observação resultou na opção por mudança do campo médico alvo da pesquisa, considerando-se especialmente o padrão técnico-estrutural dos laudos produzidos no setor de Citologia Oncótica em relação à atuação de ferramentas de IA, como exposto com mais afinco na seção “Comparação Entre o Plano Original e o Executado”




Figura 1. Trecho do fluxograma de trabalho com processos na UBS.




Figura 2. Trecho do fluxograma de trabalho com processos na Unidade da Mulher.




Figura 3. Trecho do fluxograma de trabalho com processos no HUAC.

Após a mudança no setor médico de foco da pesquisa para o setor de Diagnóstico por Imagem do HUAC, optou-se por uma busca na literatura (artigos acadêmicos publicados) com foco em conteúdos de pesquisa voltados à percepção de profissionais de Radiologia frente ao uso de ferramentas de Inteligência Artificial aplicadas a seus campos de atuação. Nesse sentido, 3 (três) artigos com foco em estudar impacto e percepção da IA na Radiologia (BRANDES *et al.*, 2020; GOTTA *et al.*, 2025; RAINEY *et al.*, 2022) foram selecionados visando promover a replicação de suas metodologias de estudo e avaliação.

Como etapa subsequente, foi elaborado um questionário piloto, o qual foi aplicado junto a médicos especialistas, residentes e técnicos de radiologia, com a finalidade de captar a percepção dos profissionais em relação ao uso de ferramentas baseadas em inteligência artificial no apoio à elaboração de laudos, à tomada de decisão clínica e ao auxílio no fluxo do trabalho. Essa etapa funcionará como norteadora para a continuação do projeto.

O questionário elaborado foi composto por 14 questões estruturadas, incluindo perguntas sobre área de atuação e tempo de experiência em laudos radiológicos, além de itens avaliados por meio de escala Likert de cinco pontos (variando de “discordo totalmente” a “concordo totalmente”), questões de resposta tricotômica (sim, não tenho certeza, não) e uma escala numérica de 0 a 10 para mensuração do nível de confiança na utilização de sistemas de inteligência artificial. Também foram incluídas questões destinadas a identificar fatores que poderiam aumentar a confiabilidade dessas ferramentas, tais como transparência do modelo, explicabilidade, validação clínica e responsabilidade profissional. O questionário buscou, assim, avaliar o grau de conhecimento prévio sobre inteligência artificial, a percepção de ameaça

ao mercado de trabalho e à função assistencial do radiologista, bem como o impacto dessas tecnologias na segurança diagnóstica.

De forma posterior à aplicação do questionário - cujos resultados e avaliação das respostas encontram-se na seção “Resultados Preliminares” - e à análise técnica das respostas obtidas, direcionaram-se os estudos para busca, e seleção, de *Large Language Models* (LLMs) de categoria *open-source* (código aberto) disponíveis na plataforma *online Hugging Face*. Os critérios utilizados na determinação dos LLMs a serem utilizados fundamentaram-se majoritariamente em: relevância do modelo a partir da quantidade de *downloads* por usuários da plataforma; gama e natureza dos dados utilizados para pré-treinamento da ferramenta computacional; e quantidade (em Bilhões) de parâmetros que compõem a estrutura do modelo.

Ao fim desta etapa, 9 (nove) modelos foram selecionados, sendo 8 (oito) construídos a partir da arquitetura de *Transformers* do tipo *decoder-only* (família GPT) – nomeadamente *BioGPT-Large*, *Mistral-7B-v0.1*, *Qwen2.5-3B-Instruct*, *Phi-3-mini-4k-instruct*, *Llama-3.2-1B*, *Llama-3.2-3B-Instruct*, *Llama-3.1-8B-Instruct* e *Bio-Medical-Llama-3.2-1B-CoT* – e 1 (um) modelado mediante a base *Bidirectional Encoder Representations from Transformers* (BERT), o *BioBERTpt-clin*, desenvolvido pela PUC - PR. A distribuição das quantidades está relacionada sobretudo à relevância tecnológica moderna dos modelos de Inteligência Artificial da família GPT em relação à capacidade computacional elevada de geração de textos.

De maneira sequencial, iniciou-se a construção de uma arquitetura geral de *fine tuning* (ajuste fino) dos LLMs selecionados a partir de ferramentas de computação em nuvem – especificamente a plataforma *Kaggle* – dedicadas à aplicação dos conceitos de Inteligência Artificial e aprendizado de máquina. Considerando-se o caráter inicial de construção do fluxo metodológico amplo para treinamento de modelos, uma base de dados pública de laudos médicos (*Galileo-AI/medical_transcription_40*), também disponível na plataforma *Hugging Face*, está sendo utilizada. O conjunto de dados em questão é composto por pareceres médicos de várias especialidades, sendo filtrados os laudos específicos de Radiologia.

Adicionalmente, no contexto de realização do ajuste fino, o *fine tuning* dos modelos é realizado a partir da estratégia *Parameter-Efficient Fine-Tuning* (PEFT), uma técnica de treinamento que permite aumentar a eficiência do processo a partir do ajuste de parâmetros pontuais dos modelos, o que diminui o tempo total do processo, ao passo que também reduz o espaço de armazenamento demandado para dados gerados via treinamento. Ademais, visando promover maior eficácia computacional ao procedimento, foram aplicadas aos modelos outras estratégias, como *quantização* e *Low-Rank Adaptation*

(LoRA). Os arquivos resultantes do ajuste fino estão sendo mantidos em repositórios alocados na plataforma *Hugging Face*.

Tal etapa representa um ponto fundamental no que tange à continuidade do projeto, atuando como base para a construção de um ambiente de *fine tuning* coeso, geral e ajustado, visando sobretudo à aplicação posterior de laudos institucionais produzidos pelo setor de Radiologia do HUAC.

Comparação entre o plano original e o executado

Inicialmente, este projeto teve como objetivo a avaliação, no HUAC, de um protótipo computacional baseado em *Large Language Models* (LLMs) para auxiliar na elaboração automática de laudos de *Citologia Oncótica* — os quais permitem atestar o desenvolvimento do *câncer de colo do útero* — por meio de reconhecimento de voz. A determinação inicial do setor alvo da pesquisa se deu majoritariamente a partir da problemática envolvendo a lentidão associada ao processo de emissão de laudos da especialidade médica em questão, fator agravado sobretudo pela mecanicidade envolvendo a elaboração desses documentos.

Dessa forma, tendo em vista a quantidade de novos casos da doença no Brasil para cada ano no triênio de 2023 a 2025, cerca de 17 mil, segundo o Instituto Nacional do Câncer (2023), e a elevada quantidade de anomalias detectadas com possibilidade de cura, segundo Araújo *et al.* (2022), identificam-se como fundamentais a periodicidade dos exames, a coleta adequada e, sobretudo, a interpretação correta dos resultados. Além disso, a agilidade no processo de emissão de laudos permite que as alterações celulares sejam detectadas precocemente, possibilitando intervenções eficazes.

Nesse sentido, o desenvolvimento de estratégias que elevem a celeridade do processo de emissão de laudos de Citologia Oncótica no HUAC viabiliza melhorias no fluxo de atendimento, apresentando grande relevância social. Do exposto, a fim de otimizar a emissão dos laudos, que devem ser avaliados pelos médicos antes da entrega ao paciente, pretendeu-se desenvolver um mecanismo de geração automática dos documentos por reconhecimento de voz, por meio do uso de Inteligência Artificial.

Contudo, ao longo do aprofundamento teórico e da análise detalhada dos laudos utilizados na prática clínica, constatou-se que os *laudos de citologia oncótica já apresentam alto grau de padronização*,

tanto em sua estrutura quanto na terminologia empregada, seguindo classificações e diretrizes amplamente consolidadas. Essa padronização reduz significativamente a variabilidade textual e a complexidade linguística do processo de elaboração dos laudos, limitando o potencial de contribuição de uma ferramenta baseada em LLMs para essa finalidade específica.

Diante desse cenário, a manutenção do objetivo inicial poderia resultar em uma solução com baixo impacto prático, apesar de tecnicamente viável. Assim, optou-se por redefinir a aplicação do projeto, direcionando o uso dos LLMs para um contexto em que seu potencial pudesse ser explorado de forma mais significativa, preservando a relevância científica, a utilidade prática e a coerência com as demandas reais do serviço de saúde.

Ademais, o foco de desenvolvimento de uma solução tecnológica para geração de laudos por reconhecimento de voz foi modificado, sendo direcionado à concepção de uma ferramenta para classificação e geração dos laudos médicos utilizando LLMs e tecnologias de Inteligência Artificial. Optou-se por essa alteração em virtude do potencial pedagógico e clínico associado à utilização de um modelo de avaliação da qualidade da construção de laudos médicos no setor de diagnóstico por imagem, de modo a beneficiar o aprendizado prático de médicos residentes e otimizar o trabalho avaliativo dos preceptores, além de contribuir para o aprimoramento da estruturação técnica dos relatórios médicos.

Acredita-se que essa redefinição não representa uma fragilidade do projeto, mas sim um processo de amadurecimento científico, fundamentado na avaliação do custo-benefício da tecnologia proposta e na busca por maior impacto assistencial e organizacional.

Outras atividades

Em um período anterior à mudança do setor de foco da pesquisa, um protótipo de sistema *web* com foco em conversão de áudio em texto foi desenvolvido utilizando ferramentas *open source* como *Whisper* (RADFORD *et al.*, 2022), um modelo de reconhecimento automático de fala para conversão em texto que possui integração à linguagem de programação *Python*, via biblioteca disponibilizada pela empresa *OpenAI*.

Além disso, tendo em vista a construção de um sistema *web*, uma interface de usuário — *Frontend* — foi desenvolvida utilizando tecnologias modernas e eficientes, como *React* e *Vite*. Por outro

lado, para operações alocadas na porção do servidor — *Backend* — , o *framework Flask*, amplamente utilizado para desenvolvimento de aplicações web escaláveis em *Python*, foi adotado como base da arquitetura, especialmente para gerenciamento de requisições e definição de rotas. Posteriormente, em virtude da alteração do setor médico alvo dos estudos, direcionou-se o foco à busca e consequente treinamento de LLMs de código aberto para outras atividades.

Em etapa subsequente, mediante a definição do setor de Radiologia como foco de pesquisa e a aplicação do questionário aos profissionais da área, foram desenvolvidos *scripts*, utilizando *Python*, para viabilização de geração, análise e tratamento dos dados obtidos a partir das questões propostas a médicos especialistas, residentes e técnicos de Radiologia.

Durante esse processo, utilizaram-se bibliotecas de *Python* como *Pandas* (MCKINNEY, 2010), *Matplotlib* (HUNTER, 2007) e *SciPy* (VIRTANEN *et al.*, 2020) para agrupamento e tratamento de dados, geração de infográficos objetivos e aplicação de métricas estatísticas, respectivamente. Tal processo viabilizou sobretudo a análise das informações obtidas, especialmente mediante gráficos e índices estatísticos específicos.

Ao longo da pesquisa, em etapas futuras, pretende-se concluir a construção de uma arquitetura geral para *fine tuning* dos modelos de linguagem selecionados. Para tal desenvolvimento, visando à construção de uma base de dados robusta e bem estruturada, deseja-se utilizar o método de avaliação *LLM As a Judge* (ZHENG *et al.*, 2023) para complementar o processo de classificação prévia dos laudos institucionais de Radiologia produzidos pelo HUAC.

Posteriormente, mediante conclusão da construção da base de dados e realização do ajuste fino dos modelos, pretende-se desenvolver um modelo geral de testes dos LLMs devidamente treinados – a partir de um conjunto de dados de testes –, analisando métricas variadas que permitam avaliar o desempenho das ferramentas após aplicação do *fine tuning*, como *acurácia*, *f1-score*, *recall*, *viés (bias)*, *taxa de alucinação*, entre outros.

Após a análise do desempenho dos modelos, visa-se observar um trade-off, escolha estratégica de sacrificar um requisito para otimizar outro, na aplicabilidade dos modelos — observando a performance e o tamanho dos modelos com melhores desempenhos definidos pelas métricas estabelecidas anteriormente —, já que um dos objetivos na aplicação dessa ferramenta é ter como referência um baixo poder computacional, sendo possível rodar localmente em servidores da Instituição.

Em seguida, planeja-se desenvolver um fluxograma de aplicação onde será definida a comunicação de cada etapa: Frontend (interface de usuário), Backend (servidor da aplicação) e LLM (Large Language Model). Essa definição do comportamento do sistema é uma etapa essencial para a

discussão, entendimento e implementação do Software. Sendo assim, após a discussão e o desenvolvimento da ferramenta, idealiza-se retornar ao Hospital Universitário Alcides Carneiro (HUAC) para obter a avaliação e as opiniões dos médicos residentes e dos médicos especialistas sobre o uso, na prática, do sistema desenvolvido.

Resultados Preliminares

De maneira anterior à mudança de foco da pesquisa, a tecnologia utilizada como base da transcrição de áudio foi selecionada a partir de testes comparativos entre a ferramenta previamente exposta no plano de projeto — *Whisper* — e outros instrumentos oferecidos, em sua maioria, pela biblioteca *SpeechRecognition*, que fornece estratégias de código aberto (em *Python*) focadas em algoritmos para conversão de áudio em texto.

Nesse sentido, a LLM *Whisper* obteve resultados satisfatórios em comparação com outras ferramentas testadas, apresentando um menor *Word Error Rate* (WER), isto é, uma menor taxa de erros de palavras durante a conversão. Adicionalmente, *Whisper* apresentou eficiência de conversão superior a outros modelos em relação a acentuação e pontuação presentes na Língua Portuguesa, o que foi determinante para sua utilização no desenvolvimento do protótipo.

No novo contexto de aplicação, os principais resultados concentram-se na articulação com o Setor de Diagnóstico por Imagem e na definição de uma nova pergunta de pesquisa, com base na compreensão do fluxo de trabalho e das demandas do serviço. Além disso, finalizou-se a aplicação do questionário piloto, com o objetivo de captar a percepção dos profissionais acerca do uso da inteligência artificial. Os resultados deste instrumento foram submetidos a análises gráficas e estatísticas.

Ao fim desta etapa, o questionário piloto foi respondido por 17 participantes, sendo aproximadamente 35% médicos especialistas (n=6), 18% médicos residentes (n=3) e 47% técnicos em radiologia (n=8), majoritariamente vinculados ao Hospital Universitário Alcides Carneiro (HUAC) (Figura 4). Entre os médicos especialistas, predominou o tempo de experiência entre 8 e 15 anos, enquanto parte significativa dos técnicos declarou não possuir experiência na elaboração de laudos radiológicos.




Figura 4. Proporção de cargos referente às respostas obtidas até o momento.

Em relação ao conhecimento sobre inteligência artificial (IA), observou-se distribuição heterogênea das respostas, com tendência a posicionamentos intermediários, sugerindo percepção moderada sobre o domínio do tema. Quanto ao impacto da IA na radiologia, a maioria dos participantes discordou ou não concordou que a tecnologia represente ameaça direta ao mercado de trabalho ou à função assistencial do radiologista, indicando que a IA é predominantemente percebida como ferramenta de apoio, e não como substitutiva, como ilustrado a partir da Figura 5.




Figura 5. Impacto potencial do feedback de IA na tomada de decisão dos Radiologistas que produzem laudos.

No que tange à confiabilidade dos profissionais de Radiologia em relação aos sistemas baseados em Inteligência Artificial para auxílio na interpretação de imagens, observou-se que aproximadamente 53% (n=9) dos profissionais entrevistados possuem confiança moderada em relação a tais ferramentas. Por outro lado, 1 (um) profissional afirmou possuir confiabilidade próxima à nula nos sistemas em questão, enquanto 2 (dois) dos entrevistados informaram confiar de maneira praticamente absoluta em modelos de IA no contexto de interpretação de imagens. Tais dados estão dispostos no gráfico apresentado na Figura 6.




Figura 6. Escala de confiabilidade dos profissionais de Radiologia em relação aos sistemas de IA para auxílio de interpretação de imagens.

Entre as funcionalidades apontadas como relevantes para aumento da confiança destacaram-se a performance/acurácia do sistema, a indicação do grau de confiança do algoritmo e recursos de explicação visual ou textual (Figura 7). Além disso, os participantes indicaram como fatores fundamentais para ampliação da confiança a maior transparência dos modelos (explicabilidade e validação clínica), definição clara de responsabilidade profissional em caso de erro e realização de auditorias relacionadas à proteção de dados.




Figura 7. Funcionalidades para aumento da confiança em sistemas de IA para diagnóstico de imagem.

Além de análises gráficas, métricas estatísticas utilizadas nos artigos que serviram como base para a replicação foram utilizadas na análise das respostas do questionário. Ao aplicar o Coeficiente de Correlação de Postos de Spearman (*Rho* de Spearman) às respostas, foi possível observar que existe uma correlação moderada entre o conhecimento declarado sobre tecnologias de IA aplicadas à Radiologia e a busca por informações a respeito do tema como critério para exercício da especialidade médica ($\rho = 0,54$, $p = 0,034$). Tal resultado sugere que profissionais que manifestam já possuir bom conhecimento associado à Inteligência Artificial tendem a afirmar que são necessárias, ainda, informações adicionais sobre funcionamento e progresso dessa tecnologia antes de optar por escolher ou não a Radiologia como campo de atuação.

Ademais, a aplicação do *Rho* de Spearman permite inferir a existência de uma associação estatisticamente significante entre a confiabilidade promovida pelo respaldo técnico de tecnologias de IA em relação ao diagnóstico por imagem do profissional, e a insegurança existente mediante a discordância entre os diagnósticos de Radiologia de um especialista e de um sistema de Inteligência Artificial ($\rho = 0,50$, $p = 0,04$). Pode-se concluir, a partir de tais valores, que a atuação de sistemas de IA no contexto de diagnóstico por imagem possui impacto significativo, podendo exercer influência sobre a confiabilidade dos profissionais de Radiologia frente a suas próprias decisões clínicas.

Em suma, os achados iniciais indicam percepção moderadamente positiva em relação à aplicação da Inteligência Artificial na Radiologia, associada à necessidade de maior transparência, segurança jurídica e validação técnica para consolidação de sua aceitação na prática clínica. Além disso, os resultados sugerem que o impacto de ferramentas de IA na Radiologia, especialmente no campo de diagnóstico por imagem, é de extrema relevância técnica e acadêmica, pois refletem a difusão de tais tecnologias computacionais entre os profissionais da área - com influência significativa em decisões clínicas -, ao passo que viabilizam a continuidade deste projeto.

No que tange à análise preliminar do processo de *fine tuning* dos LLMs selecionados para classificação e geração dos laudos médicos de Radiologia, é perceptível o ganho de eficiência em armazenamento necessário para manutenção dos arquivos que compõem os parâmetros dos modelos. Nesse sentido, técnicas como *PEFT*, *quantização* e *LoRA* permitem reduzir, no caso do modelo *Mistral-7B-v0.1*, por exemplo, em mais de 99% – de 29,5 GB (como especificado no repositório na plataforma *Hugging Face*) para apenas 87,5 MB – o volume de dados armazenados do modelo resultante. Tal processo é fundamentado majoritariamente no *ajuste de apenas um conjunto específico de parâmetros durante Low-Rank Adaptation*, procedimento no qual a maior parte dos pesos pré-treinados é mantida congelada (HU et al., 2021). Este método se apresenta como alternativa ao ajuste fino global de parâmetros (*full fine tuning*), o qual demandaria mais poder computacional de processamento e armazenamento.

De forma similar, o processo de *quantização* de parâmetros do modelo destacado anteriormente revela, em análise inicial, ganho significativo em relação à otimização do consumo de memória de *hardware*. O aumento da eficiência é referenciado pelo carregamento e treinamento completos de *Mistral-7B-v0.1*, um modelo composto por mais de 7 (sete) bilhões de parâmetros, em um sistema de computação em nuvem – *Kaggle* – composto pela *Graphics Processing Unit* (GPU) *P100*, cujas especificações retratam 16 (dezesesseis) GB de *Video Random Access Memory* (VRAM). Nesse sentido, a compressão dos parâmetros do LLM utilizando a representação *NormalFloat* de 4 bits (NF4) sugere um caráter promissor para *fine tuning* estruturado e otimizado (DETTMERS et al., 2023).

Tem-se, portanto, que a utilização de técnicas de *fine tuning* eficiente constitui uma camada essencial da pesquisa, permitindo compreender como o uso de estratégias computacionais diversas interfere na aplicação prática do treinamento de LLMs. Por conseguinte, a solidificação de tais metodologias, visando posterior aderência ao contexto de geração e classificação de laudos médicos de Radiologia do HUAC, fundamenta os estudos científico e tecnológico, viabilizando a produção de conhecimento acadêmico especializado.